

AI 顶层设计图谱

真正值得比较的不是参数量或模型榜单，而是智能系统如何被约束、怎样判断、谁拥有控制权、遇到未知时如何泛化，以及安全责任落在哪一层。

[← 返回 AI 栏目](#)

顶层设计决定的，是智能如何被组织

真正应该比较的不是“谁的模型更强”，而是每家公司把规范、判断、控制、反馈、泛化与禁区放在哪一层解决。

SYSTEM MODEL

$$S = (G, R, H, F, A, B)$$

一个 AI 系统的顶层设计，可以压缩为六个相互制约的变量。

G

Goal

系统为什么行动？

R

Rules / Principles

依据什么行动？

H

Hierarchy

指令冲突时听谁的？

F

Feedback

判断错了怎么修？

A

Adaptation

新情境中如何泛化？

B

Boundary

哪些事绝不能做？


TOP-LEVEL DESIGN

为什么行动 → 依据什么 → 听谁的 → 错了怎么修 → 未知中如何判断 → 边界在哪里

阅读基线：页面只整理附件对各家公开材料的描述。公开文档的性质、完整度与更新时间不同；未公开对应层级的完整治理文档，不等于不存在内部治理体系。

五家公司，并不在设计同一种系统

把五家强行排成一条高低顺序会误导分析。它们公开材料所突出的问题，分别落在价值、权限、风险、效率和行动五个不同方向。



ANALYSIS RULE

比较时先确认“控制点在哪一层”，再比较具体机制；否则容易把模型规范、平台权限、实验室治理、计算架构和智能体能力混成同一指标。

切换五个控制中心，看系统如何作出决定

同一个“安全与可控”目标，可以通过不同控制点实现：原则、权限、能力阈值、优化目标或任务执行回路。



CONTROL = AUTHORITY

权限分层

平台控制架构

Root > System > Developer > User > Guideline > Untrusted

附件把 Model Spec 抽象为高度工程化的权力拓扑：重点不是让每个节点共享同一哲学，而是明确指令冲突时谁说了算。

机制

Authority Resolution

目标

AI Platform Governance

CONTROL = CAPABILITY THRESHOLD

风险阈值

实验室治理

State → Threshold → Evaluation → Mitigation → Restriction

附件认为 Google 的公开框架更关注模型能力发展到何种程度后，实验室应触发评估、缓解与部署限制。

对象

AI Capability

目标

Control Dangerous Capability

CONTROL = OPTIMIZATION

计算效率

开放智能引擎

$\eta = \text{Capability} / \text{Compute}$

附件中的公开材料重点落在架构、训练与推理效率：在给定计算资源下，尽可能提高智能生产效率。

机制

Architecture + Training + Inference

目标

Maximize Intelligence under C

CONTROL = TASK EXECUTION

智能体行动

任务完成系统

Goal → Plan → Tool → Observe → Replan → Complete

附件把 Kimi 的公开技术重点概括为工具调用、长链执行和智能体训练：系统目标从生成答案转向完成任务。

机制

Agentic Execution Loop

目标

Action Capability

三个闭源体系，把控制点放在三个层级

Anthropic、OpenAI 与 Google 的公开文件并不是三个同层方案。它们分别控制模型怎样判断、平台怎样分配权力，以及实验室何时必须制动。

03 · CIVILIZATION / LAB

Google

能力风险治理

控制对象是实验室与模型能力阈值。

Capability → Threshold → Mitigation



02 · PLATFORM / INSTRUCTION

OpenAI

权限与冲突解决

控制对象是模型、工具、开发者和用户组成的平台网络。

Authority → Priority → Action



01 · MODEL / COGNITION

Anthropic

原则与判断泛化

控制对象是模型内部的价值解释与具体判断。

Principle → Judgment → Action

ANTHROPIC ASKS

模型应该怎样判断？

把复杂性从规则数量转移到价值解释与原则冲突。

$$\text{Action} = f(\text{Context}, \text{Principles})$$



OPENAI ASKS

谁有权决定行为？

把复杂性组织成可操作、可配置但有根边界的权限拓扑。

$$\text{Action} = \arg \max \text{Priority}(\text{I}_i)$$

开放权重改变的，是安全责任的系统边界

“开放还是闭源”不只是分发方式。模型能否离开原厂控制环境，会改变平台、部署者与下游治理之间的责任分配。

CLOSED SERVICE

模型与平台不可分离

$$\text{Safety} = \text{Model} + \text{Platform} + \text{Policy} + \text{Monitoring}$$

厂商能够把模型、权限、策略、工具和监控放在同一个受控环境中。

- 控制边界更集中
- 持续策略更新
- 平台级访问控制

OPEN WEIGHTS

模型进入不同部署环境

$$\text{Safety} = \text{Model} + \text{Downstream Governance}$$

行为边界在更大程度上由部署者、工具权限、数据环境与下游监督共同决定。

- 系统边界更开放
- 部署情境更多样
- 责任向下游迁移

EFFICIENCY ENGINE

DeepSeek：资源约束优化

$$\text{Given Compute} = C, \text{ maximize Intelligence}$$

公开技术哲学集中在单位资源的智能产出。

Kimi：任务执行优化

Answering → Planning → Acting

公开技术哲学更强调工具协同与任务完成。

重要限定：“没有公开同层级文档”与“没有安全或治理体系”不是同一命题。本页只比较附件呈现出的公开设计重点。

从结构模型到网络化行动系统

大模型已经不再是单一网络。模型、路由器、工具、智能体、用户、记忆与外部系统组成新的计算网络，不同公司在这条演化链的不同位置下注。

01

STRUCTURE

结构系统

MoE、Dense、Transformer 与专家网络回答“系统由什么构成”。

DeepSeek / Kimi 公开较多

02

INFORMATION

信息系统

Attention、多模态 token 与上下文回答“信息如何编码传递”。

多模态体系的重要战场

03

CONTROL

控制系统

权限层级决定复杂网络中谁能覆盖谁的指令。

OpenAI 的公开重点

04

SELF-ORGANIZATION

自组织系统

系统从一般原则出发，在未知情境中生成具体判断。

Anthropic 的公开重点

05

COMPLEX ADAPTATION

复杂适应系统

策略根据人类、模型、工具与环境反馈持续更新。

所有厂商都已进入

06

NETWORK + COMPUTE

网络与计算复杂性

Models + Routers + Tools + Agents + Users + Memory 形成智能基础设施。

当前共同前沿


NETWORKED AI

$$G = (V, E)$$

控制问题从“单个模型怎样回答”扩展为“智能网络怎样分配价值、权限、风险、资源与行动能力”。

五条路线构成状态空间，不是一维排行榜

“更先进”必须先说明评价维度。价值泛化、权限组织、风险治理、计算效率和行动能力之间存在协同，也存在无法回避的张力。



成熟系统最终需要重新整合这些专长

未来未必会证明某一家哲学完全正确。更可能的结果，是分化后的原则、权限、风险、效率和行动能力重新组合为更高阶系统。



FINAL SYSTEM

AI 顶层设计的终局，不是某一项局部指标胜出，而是原则判断、权限治理、风险阈值、计算效率与智能体行动在同一系统中保持可解释的动态平衡。

Reasoning + Values + Authority + Risk Control + Efficiency + Agency

阅读边界： 厂商文档、模型结构和产品策略会持续变化。本页呈现的是附件中的系统论抽象，不构成对当前模型能力、安全水平或商业选择的实时结论。