

第三方 API 模型接入清单

14 个模型与服务，按文本、图像、语音和视频四类整理能力价值、使用场景、当前状态与官方价格。

← 返回AI栏目

API MODEL MATRIX · 核实于 2026-06-04

从 PDF 文本层与版式坐标逆向还原，覆盖当前工作流通过 API 接入的文本推理、图像生成、语音合成和数字人/视频服务。

14

接入模型 / 服务

4

能力类别

9

厂商 / 平台

8/9

价格官方已核实

01 文本 LLM · 推理与对话

4 项

Claude (Anthropic)

Opus 4.8 · Sonnet 4.6

官方直连

● 主力

当前**推理质量天花板**，Agentic 编码与复杂多步任务最稳，工具调用可靠。Sonnet 享 1M 长上下文。

推理最强

Agentic 编码

长上下文 1M

工具调用稳

场景 Claude Code 核心引擎、复杂编码与多步推理

\$5 / \$25

Opus 4.8 输入 / 输出 (每百万 token)

Sonnet 4.6 \$3 / \$15; 缓存读取 0.1x; Batch 5 折

console.anthropic.com ↗

OpenRouter

LLM 聚合路由

300+ 模型统一网关

● 主力

一个 Key 统一访问 **300+ 跨厂商模型**，自动故障转移与负载均衡，切换零成本，不被单一厂商锁定。

300+ 模型

一个 Key

自动容灾

不锁厂商

场景 多模型统一调度、对话与内容生成的中转层

原价透传 不加价

充值收 5.5% 手续费; BYOK 每月前 100 万次免费, 之后 5%

openrouter.ai ↗

Gemini Flash (Google)

2.5 / 3.x Flash

Google AI Studio

● 主力

高性价比多模态模型，**原生支持文件上传与视频分析**，超大上下文。适合大批量、低延迟的理解类任务。

多模态

视频分析

超大上下文

便宜

场景 视频内容分析、大批量文本理解与分类

\$0.30 / \$2.50

2.5 Flash 输入 / 输出 (每百万 token)

3.5 Flash \$1.50 / \$9; Flash-Lite 低至 \$0.10 / \$0.40

aistudio.google.com ↗

Qwen3 (SiliconFlow)

Qwen3.5 系列

硅基流动 · 国内直连

● 主力

国内直连的开源 Qwen3 托管推理，单价极低、低延迟，适合高频小任务。新账号含免费额度。

国内直连

单价极低

低延迟

开源模型

场景 意图分类、关键词抽取等高频轻量任务

¥0.40 起 / 百万 token

输入 ¥0.40–1.20 (0–128k 档)

输出 ¥3.20–7.20; 长上下文文档约 2.5–4×

siliconflow.cn ↗

02 图像生成 · 文生图与编辑

6 项

Gemini 3 Pro Image

gemini-3-pro-image-preview

Google · nano-banana-pro

● 主力

原生 4K + 最高保真度，多参考图严格一致性，中文文字渲染最佳。40s 出 4K 不需 upscale。

原生 4K 多参考图一致 中文文字准 色彩还原强

场景 商业级成片、4K 电商产品图、隐形模特

≈ \$0.13 / 张 (1-2K)

4K 约 \$0.24/张；输入 \$2、图像输出 \$120（每百万 token）；Batch 半价

aistudio.google.com ↗

Gemini 3.1 Flash Image

gemini-3.1-flash-image-preview

Google · nano-banana 2

● 主力

1024 原生分辨率，**快且便宜**，中文渲染好。Pro 版的轻量替身，用于不追 4K 的高频出图。

快 便宜 中文好 1024 原生

场景 中文 slogan 配图、内容快稿迭代

≈ \$0.045 / 张起

\$0.045 (0.5K) → \$0.151 (4K) 按分辨率
输入 \$0.50、图像输出 \$60（每百万 token）

aistudio.google.com ↗

gpt-image-2 (OpenAI)

gpt-image-2

OpenAI 官方直连

● 主力

指令跟随与图像编辑最强：保留原图主体换场景、重建光影逻辑。edits 最多 16 张参考图。

编辑最强 产品一致性 光影逻辑 16 张参考图

场景 产品换场景、风格迁移、角色跨镜一致性

≈ \$0.05 / 张 (1024² 中)

低 \$0.006 · 高 \$0.21; 图像输入 \$8、输出 \$30 (每百万 token) ; Batch 5 折

platform.openai.com ↗

即梦 Seedream 4.0

doubao-seedream-4-0

火山方舟 Ark · 国内直连

● 可用

中文理解与文字渲染强，多图融合（最多 10 张）、序列图（最多 15 张）。国内直连、单张成本最低。

中文准

多图融合 10

序列图 15

国内最便宜

场景 中文商业素材、批量风格统一配图

¥0.20 / 张

按输出图片计费 (RMB)

商业素材务必走 API，不用 Web UI

console.volcengine.com/ark ↗

fal.ai

FLUX / Seedream / Nano Banana

多模型聚合平台

● 备用 · 余额耗尽

一个 API 聚合多家开源/托管图像视频模型（含 Recraft 矢量化），按产出计费，排队与服务端错误不收费。

多模型聚合

矢量化

按产出计费

错误不收费

场景 跨模型快速试验、矢量 logo、备用通道

\$0.03 / 张起

Seedream V4 \$0.03 · Nano Banana \$0.0398 · FLUX Kontext Pro \$0.04/张

fal.ai/pricing ↗

可灵 Kling

Kling · Kolors 可图

快手可灵开放平台

● 暂停 · 无余额

视频生成业界领先（运动幅度 / 时长），图像生成（可图 Kolors）中英文字渲染强，面向 B2B 集成。

视频运动强

长时长

中英文字准

B2B

场景 高动态视频生成（图像为辅）

\$1 = 66 积分

≈\$0.015/积分；视频 9-16 积分/秒

图像单价未公开核实（站点拦截抓取）

klingai.com/global/dev ↗

03

语音 TTS · 合成与克隆

2 项

MiniMax TTS

speech-2.8-hd

MiniMax · 国内直连

● 主力

高拟真、情感丰富的中文 TTS，当前最高质量档。支持音色克隆、timber 混音与跨语种。

- 最高拟真
- 音色克隆
- 混音
- 跨语种

场景 微信语音回复、视频号口播、数字人配音

¥3.5 / 万字符

turbo 档 ¥2/万字符；按输入字符计，1 汉字 = 2 字符

platform.minimaxi.com ↗

Qwen3-TTS（阿里云百炼）

- qwen3-tts-flash · cosyvoice-v3-plus

DashScope · 国内直连

● 迁移中

17 种方言 + 10 种外语，音色克隆 1 年有效（MiniMax 仅 7 天），自然语言情绪控制。单价低于 MiniMax。

- 17 方言
- 克隆 1 年
- 情绪控制
- 更便宜

场景 微信语音（已上线）、视频号口播替换中

¥0.115 / 万字符

qwen3-tts-flash 国内价；音色复刻 \$0.01/个

bailian.console.aliyun.com ↗

04 数字人 / 视频 · 生成

2 项

石榴数字人

- 16ai · createByAudioFile

向量方程科技

● 可用

一站式数字人：声音合成 + 形象训练（照片/视频建模）+ 音频驱动视频生成。覆盖广告、医疗、教育等行业。

一站式

音频驱动

照片建模

多行业

场景 数字人口播视频（TTS 出音 → 驱动形象）

¥6 / 分钟

数字人视频生成 ¥6 / 分钟

api.16ai.vip ↗

即梦视频 Seedance

doubao-seedance-1.0-pro / fast / lite

火山方舟 Ark · 国内直连

● 可用

文生 / 图生视频。 1.0-pro 高画质，pro-fast 提速 3 倍、降价 72% 量产，lite 入门档。国内直连。

文生/图生视频

高画质 pro

量产 fast

国内直连

场景 短剧、水墨漫剧、视频号批量出片

¥3.67 / 5s 1080p

1.0-pro ¥15/百万 token；pro-fast ≈¥1.03/5s；离线 Batch 5 折

console.volcengine.com/ark ↗

价格说明 · 上表价格于 2026-06-04 核实自各厂商官方定价页，单位与币种以原页面为准（USD / RMB 混用，已标注）。除可灵图像单价（站点拦截抓取）外，其余均锚定官方页面。

价格随官方政策动态调整，实际计费以下单时官网为准。缓存、Batch、长上下文等折扣档详见各官方文档。